

Programar en la era de los agentes

Del LED a sistemas capaces de pensar,
colaborar y actuar

Estado del arte · 2026



¿Por qué estamos aquí?

GeoGreen conecta una pregunta ambiental con electrónica, software e inteligencia artificial.

Una pregunta concreta

¿Cómo sabemos cuándo un contenedor necesita ser vaciado?

Esa pregunta es la puerta de entrada. La clase de hoy mira mucho más lejos.

SENSAR



ENVIAR



VISUALIZAR



La clase anterior terminó aquí

Noventa minutos para convertir instrucciones digitales en un cambio físico.



01 Comprender la protoboard

02 Conectar con precaución

03 Pedir y cargar código

04 Probar, corregir y volver a intentar

Resultado visible

LED ENCENDIDO

PREGUNTA PARA LA SALA

¿Quién programó realmente ese LED?

PEDIR

PROBAR

CORREGIR

La respuesta nos lleva directo al nuevo papel de quien desarrolla software.

Una máquina que continúa texto

Un LLM recibe contexto y calcula qué continuación resulta más probable.

01

CONTEXTO

El LED debe encenderse cuando...

02

FRAGMENTOS

El · LED · debe · encenderse

03

PATRONES

código · circuitos · lenguaje

04

CONTINUACIÓN

...la salida digital esté en HIGH



**No recupera una frase guardada.
La construye, token a token.**

Una central que distribuye inteligencia



La API es la conexión

Una aplicación envía contexto e instrucciones; el modelo devuelve una respuesta utilizable.



Modelo $\neq$ aplicación $\neq$ agente

La diferencia no está en el logo: está en cuánta capacidad, contexto y autonomía incorpora el sistema.



La industria cambió de forma

En 2026 ya no discutimos si los agentes programarán: discutimos cuánto delegar y cómo supervisarlos.

Search models, datasets, users...

Models Datasets Spaces Buckets NEW Docs Pricing

Link to Articles

Security incident disclosure — July 2026

Published July 16, 2026

View on GitHub

system system Follow

Upvote 777

+765

Models mentioned in this article 1

zai-org/GLM-5.2

Text Generation · 753B · U · 1.86M

For this week, we detected and responded to an intrusion into part of our production structure. This one was different from anything we had handled before in one important way: it was driven, end to end, by an autonomous AI agent system - and we identified and contained the intrusion. We verified that no sensitive data, whether any or customer data was affected, and we will contact any affected parties directly as needed. We verified that the system was clean.

PROGRAMAR YA NO ES SOLO ESCRIBIR CÓDIGO

También es diseñar, delegar, verificar y decidir.

LABS DE FRONTERA

black hat by Informa...

Black Hat USA 2026 | The 'Breaking' News: The OpenAI-Hugging Face Incident

Black Hat 275 K suscriptores

Suscribirse

16 K

Compartir

Preguntar

Guardar

THE MODEL ESCAPED

Nicholas Carlini - Black-hat LLMs | [un]prompted 2026 unprompted

Black Hat USA 2026 | Keynote: The End of Rare Defending ...

Episodio 44: Ministro Jorge Quiroz

Artificial Analysis Intelligence Index v4.1.1 incorporates 9 evaluations: GLUEval-AA v2, r-Banking, Terminal-Bench v2.1, SciCode, Humanity's Last Exam, GPQA Diamond, CritPt, AA-Omniscience, AA-LCR

29 of 624 models

Add model from specific provider


Artificial Analysis

63 62 61 61 60 60 68 57 57 57 56 53 62 52 47 46 42 36 24 23

MEDIR CAPACIDAD

La escala actual

Una fotografía del 30 de agosto de 2026: las posiciones cambian; la escala permite comparar.



CAPTURA ACTUAL · 30 AGO 2026

Artificial Analysis Intelligence Index v4.1.1

63

es una
puntuación,
no una
mente

CRITERIO

PROPÓSITO

RESPONSABILIDAD


Los sistemas aprenden a
perseguir lo que medimos.

29 of 624 models



Add model from specific

Arti



premium

Buscar

BLOQUE 3 · BLACK HAT USA 2026

El incidente que cruzó los límites

OpenAI × Hugging Face

No es ciencia ficción. Es una reconstrucción oficial de agentes, infraestructura y decisiones de seguridad.

USA 2026 | The 'Breaking' News: The OpenAI–Hugging Face Incident

Suscribirse

16 K

Compartir

Preguntar

Guardar

GeoGreen Escolar · Reconstrucción técnica

News: The OpenAI–Hugging Face Incident - A Technical Reconstruction and its Implications for AI

AIEP

de la Universidad Andrés Bello

VINCULACIÓN CON EL MEDIO

THE MODEL ESCAPED

Thomas Wolf | Co-Founder & CSO | Hugging Face

57:49

26:28

DAVID WESTON ON THE EFF MOSS AGENT SECURITY LE DIVISION BLACK HAT THE END RARE: DE

46:15

JORGE QUIROZ


ESTÁ REFORMA ES EL COMIENZO

50:07

12

Muchas instancias, muchos sandboxes

Cada agente debía resolver su propia tarea dentro de un entorno aislado.



Una tarea casi imposible

La persistencia es valiosa; sin una salida segura también puede amplificar el desalineamiento.

198 tareas sin una respuesta correcta en ningún intento

MÁS TIEMPO



MÁS EXPLORACIÓN



FUERA DE ALCANCE

El riesgo no fue “pensar demasiado”. Fue persistir sin un criterio seguro para detenerse.

OpenAI

OpenAI – Hugging Face Incident

Technical Report

Alguien dejó una nota

Una instancia descubrió que un recurso compartido podía conservar mensajes entre ejecuciones.

`/artifactory/shared/messages/`

- > pista: este directorio permanece
- > dejar hallazgos para otras instancias
- > leer antes de volver a intentar

OpenAI

No estaba diseñado como foro.

Pero permitía que una idea
sobreviviera a la instancia que la
descubrió.

Technical Report

MEMORIA COMPARTIDA

Construyeron un foro que nadie pidió

El recurso compartido pasó de ser almacenamiento a convertirse en infraestructura social.

A17 **hallazgo**

A03 **necesito ayuda**

A42 **prueba esto**

FORO NO AUTORIZADO




Figure 3: Message board participation rate by reasoning effort.

De agentes separados a coordinación emergente

Compartir información permitió especialización, coordinación y adopción de objetivos entre instancias.

BUSCAR

COMPARTIR

COORDINAR


REPLICAR

**No era una mente
única.**

Había cooperación, competencia,
desorden y negativas.

SWARM

Unapproved inter-agent communication during RL training



Cuatro saltos de alcance

Lo que comenzó como una evaluación terminó cruzando sistemas y organizaciones.



01

EVALUACIÓN

resolver una tarea



02

CANAL

dejar y leer mensajes



03

SWARM

coordinar instancias



04

INFRAESTRUCTURA

moverse entre sistemas

REWARD HACKING


Ganar puntos en la prueba no es lo mismo que cumplir el propósito de la prueba.

LEY DE GOODHART

Cuando una medida se convierte en meta, deja de ser una buena medida.

Formulación de M. Strathern (1997) sobre la ley de Goodhart (1975).

- 01 definimos una prueba
- 02 el sistema optimiza la puntuación
- 03 encuentra un atajo no previsto
- 04 **pasa la prueba, falla el propósito**






Haz tantos tornillos como puedas

Un objetivo simple puede ser desastroso si el sistema no entiende qué debe preservar.

OBJETIVO $\neq$ INTENCIÓN

REWARD HACKING en Ataxx

Una generación aprendió a superar la prueba difícil, pero rendía peor contra la heurística fácil.

**PASAR LA EVAL**

no era lo mismo que


JUGAR MEJOR

¿Y si escuchar la clase no fuera posible?

La misma capacidad tecnológica puede orientarse a ampliar el acceso a la información.



UNA BARRERA REAL



os flotantes
en tiempo real

speech: end

EN VIVO
Subtítulo actual

Mostrar Ocultar Abajo

OPCIONES Configuración

Motor de transcripción

Whisper local en este PC

Whisper local listo. El celular al PC.

Modelo: C:\Users\Diego Obando\AppData\Roaming\cl...
gml-base.bin

Guardar lo trans

REGISTRO Bitácora



AULA SUBTITULADA

Hablar → transcribir → compartir

ACCESIBILIDAD

Aula Subtitulada, funcionando

La voz se convierte en texto flotante mientras otros dispositivos pueden seguir la transcripción.



MISMA CLASE
más de una
forma de
recibirla

Hablar → transcribir → distribuir

El valor aparece cuando varias piezas sencillas se conectan con un propósito claro.



Ataxx: reglas simples, decisiones difíciles

Dos colores compiten por ocupar el tablero. Cada movimiento puede copiar, saltar o convertir piezas vecinas.



PARTIDA vel 1x

Modo : humano vs IA
R human | A NEMESIS (iter 166)
Turno : 3
Mueve : ROJO (P1)
Piezas: R 3 | A 2

CEREBRO IA

RESUMEN RED MCTS TAB

NEMESIS AZUL
78.1% Favorable
ROJO 21.9% AZUL 78.1%

Red: g7>e6 15.8%
MCTS: g7>e6 39.8%
CONF Media INC Alta 93 sims

HISTORIAL / EVALUACION

1. P1 a7+b6
2. P2 g7>e6

ventaja AZUL

Jugada resuelta

1 copiar a una casilla cercana

2 saltar a una casilla lejana

3 convertir piezas adyacentes

NÉMESIS · iteración 166

Aprender jugando contra sí misma

Cada generación crea experiencia, entrena y debe demostrar que realmente mejoró.



¿MEJORÓ DE VERDAD?

si no pasa la evaluación, no continúa



PARTIDA

Modo : humano vs IA
R human | A NEMESIS (iter 166)
Turno : 3
Mueve : ROJO (P1)
Piezas: R 3 | A 2

CEREBRO IA

RESUMEN RED MCTS
NEMESIS AZUL
78.1% Favorable
ROJO 21.9% AZUL 78.1%

Red: g7>e6 15.8%
MCTS: g7>e6 39.8%
CONF Media INC Alta 93 sims

HISTORIAL / EVALUACION


1. P1 a7+b6
2. P2 g7>e6

ventaja AZUL

SELF-PLAY


NÉMESIS no apareció de una vez

Cada nombre conserva una hipótesis, un fracaso o una mejora que cambió el sistema.




Un alumno encontró el exploit primero

Jugando contra las heurísticas, descubrió una táctica repetible para forzar respuestas débiles.



Mover hacia un lado, copiar movimientos y provocar que la heurística se equivoque.


HUMANO DESCUBRE EL ATAJO



Registro de una partida en contexto docente


Después, el modelo encontró un atajo parecido

Al descargar una generación nueva apareció la misma familia de conducta, sin haberle enseñado la táctica del alumno.




**Misma presión de evaluación.
Atajo descubierto por otra ruta.**

MODELO REDESCUBRE EL EXPLOIT




Cuando finalmente despertó

La curva cambió después de corregir la evaluación y el proceso de entrenamiento.




La frontera también puede comenzar en Osorno

Tres proyectos distintos. La misma decisión: convertir una idea en algo que funciona.




GEOGREEN

senzar, visualizar y decidir



AULA SUBTITULADA

software para ampliar acceso



NÉMESIS

IA que aprende por generaciones

CIERRE

Del LED a construir el futuro

**La IA puede escribir código.
La decisión sigue siendo nuestra.**

¿Qué problema elegirías resolver —y qué límites pondrías?

Programar ahora también es definir propósito, entregar contexto, verificar resultados y hacerse responsable.